

Aula 15

Mapas Auto-Organizáveis

Rafael Geraldeli Rossi


Self-Organizing Maps

- Redes Neurais *SOM* (Self-Organizing Maps)
 - Aprendizado não supervisionado
 - Agrupamento de Dados
- **Agrupamento de dados:** separar os objetos de forma que objetos semelhantes pertençam ao mesmo grupo e objetos pouco semelhantes pertençam a grupos diferentes
- Base neurológica
 - Áreas sensoriais diferentes (visão, audição, olfato, ...) são mapeadas em regiões diferentes do córtex cerebral
 - Cada região se “especializa” em uma função → cada conjunto de neurônios se especializa para processar determinado tipo de informação

Self-Organizing Maps

Áreas funcionais


- 1- Áreas pré-frontais
- 2- Área motora secundária
- 3- Área motora primária
- 4- Área somatossensorial primária
- 5- Área somatossensorial secundária
- 6- Área visual secundária
- 7- Área visual primária
- 8- Área de Wernicke
- 9- Área auditiva secundária
- 10- Área auditiva primária
- 11- Área de Broca



Self-Organizing Maps


- Originalmente proposto por Kohonen [Kohonen, 1990] (também conhecidos por Mapas de Kohonen)
- **Idéia básica**
 - A posição espacial de um neurônio de saída em um mapa (camada de neurônios de saída) corresponde a um domínio particular (ou tema, tópico, característica, ...)
 - Os exemplos são apresentados para a rede
 - A rede se **auto-organiza** de forma que os **exemplos mais parecidos ativem neurônios de uma mesma região** e **exemplos diferentes ativem neurônios de regiões diferentes**

Self-Organizing Maps



<https://chi3x10.files.wordpress.com/2008/05/result1.jpg>

Self-Organizing Maps




<https://www.whitestein.com/sites/default/files/styles/max-w-1000/public/SurfacePlotSOM.png?itok=>

X3CTaBXR

Self-Organizing Maps

- Uma rede som terá **uma camada de entrada e uma camada de saída**



Self-Organizing Maps

- Cada neurônio da camada de saída está conectado à todos os neurônios na camada de entrada (ou vice-versa)
- Para facilitar o entendimento do problema, podemos considerar que cada neurônio da camada de saída possui um vetor de pesos (cada peso representa o peso de uma conexão com um neurônio da camada de entrada)
- Assim como o treinamento supervisionado de uma rede neural baseada em perceptron(s), o aprendizado consistirá em ajustar os pesos das conexões

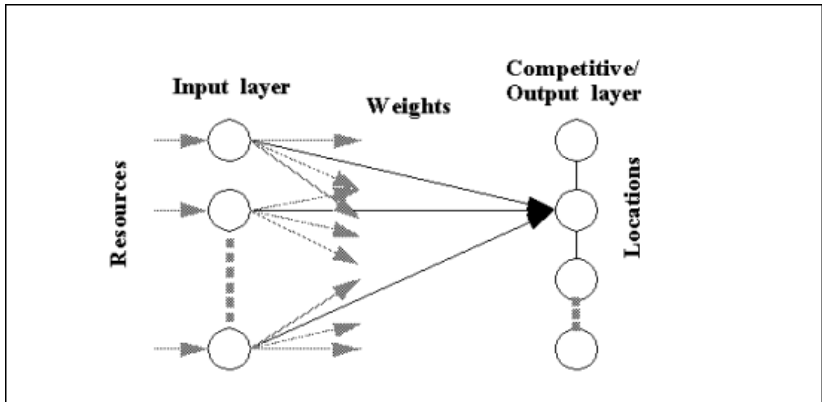


Self-Organizing Maps

- Cada neurônio da camada de saída também está conectado a outros neurônios da camada de saída (seus vizinhos imediatos)
- Essas conexões também serão úteis na atualização dos pesos dos neurônios (aprendizado) → influenciar sua região para que os neurônios próximos respondam a estímulos parecidos
- Comumente utilizam-se estruturas uni, bi ou tridimensionais para agrupar os neurônios da camada de saída (topologia da camada de saída)
- Vale ressaltar que é preciso mapear a posição de cada neurônio para depois ser utilizada no aprendizado

Self-Organizing Maps


Exemplo de uma rede SOM com camada de saída unidimensional



<https://www.girardin.org/luc/cgv/www5/nn.gif>

Self-Organizing Maps


Exemplo de uma rede SOM com camada de saída bidimensional



<http://www.decom.ufop.br/imobilis/wp-content/uploads/2017/05/kohonen1.gif>

Self-Organizing Maps


Exemplo de uma rede SOM com camada de saída tridimensional



https://www.mathworks.com/help/examples/nnet/win64/RefPlotsomExample_04.png

Self-Organizing Maps


Exemplo de uma rede SOM com camada de saída tridimensional




https://www.mathworks.com/help/examples/nnet/win64/RefPlotsomExample_05.png

Self-Organizing Maps

- A forma de conectar os neurônios na camada de saída também pode variar
 - Conexões somente nas verticais e horizontais
 - Conexões nas verticais, horizontais e diagonais



a) Conexões nas horizontais e verticais



b) Conexões nas horizontais, verticais e diagonais

Self-Organizing Maps

- Os pesos de cada neurônio são inicializados aleatoriamente
- O treinamento da rede consistirá (como sempre) em ajustar o peso dos neurônios de forma que dado os valores das características de um exemplo, esse seja “redirecionado” para uma determinada área do mapa de neurônio
- A área será influenciada pelo exemplo apresentado a rede
- Ao final, cada neurônio representará um conjunto de exemplos (exemplos que ele “dispara”)
- Áreas da rede poderão ter neurônios parecidos (dependendo do número de neurônios na camada de saída)

Self-Organizing Maps

- O treinamento da rede possui **3 etapas básicas**:
 - **Competição**:
 - Para cada padrão apresentado, os neurônios competem entre si
 - O neurônio que melhor responde ao estímulo é ativado (neurônio vencedor)
 - **Cooperação**: o neurônio vencedor compartilha parte do seu estímulo com neurônios da sua vizinhança
 - **Adaptação Sináptica**: os neurônios estimulados ajustam seus pesos em direção ao estímulo recebido

Self-Organizing Maps

• Algoritmo de Treinamento do SOM

- ① **Inicialização:** definição dos pesos iniciais dos neurônios
- ② **Amostragem:** escolha aleatoriamente um exemplo de entrada para apresentar à rede
- ③ **Competição:** escolha o neurônio vencedor → aquele que apresentar a menor distância Euclidiana entre o exemplo de entrada e o vetor de pesos dos neurônios
- ④ **Cooperação:** escolha neurônios na vizinhança do neurônio vencedor
- ⑤ **Adaptação Sináptica:** ajuste os pesos de cada neurônio considerando
 - ① A distância em relação ao neurônio vencedor
 - ② Uma taxa de aprendizado
- ⑥ **Repetição:** repetir os passos 2 a 5 até um critério de parada (nº máximo de iterações e/ou pequena alteração dos pesos sinápticos).

Inicialização

- **Pode-se inicializar os neurônios:**
 - Aleatoriamente
 - Baseados em uma distribuição normal
 - Aleatório mas considerando o intervalo de valores dos atributos
 - Técnicas mais sofisticadas como análise de componentes principais
 - ...

Amostragem

- Dada uma coleção de exemplos D e um índice t , $1 \leq t \leq |D|$
- Deve-se escolher um índice t
 - Aleatoriamente
 - Sequencialmente

Competição

- Escolher o neurônio vencedor (*BMU - Best Matching Unit*)
- Para tal, compara-se a distância do exemplo com a distância do vetor de pesos de um neurônio
- O neurônio que apresentar a menor distância é o BMU
- Normalmente utiliza-se a distância Euclidiana

Cooperação / Adaptação Sináptica

- A rede neural não começa perfeita logo de início
- Portanto é necessário adaptar os pesos de rede de acordo com os estímulos recebidos
- Como falado anteriormente, não só o neurônio vencedor como seus vizinhos recebem estímulos e são adaptados
- Entretanto, faz mais sentido o neurônio vencedor ser “mais adaptado” em relação ao seu estímulo do que seus vizinhos

Cooperação / Adaptação Sináptica

- Lembrando que no aprendizado supervisionado de uma rede neural, os pesos são ajustados de forma a prever corretamente a saída desejada de um exemplo
- No caso do aprendizado não supervisionado, os pesos são ajustados para corresponder aos valores dos exemplos de entrada (estímulos)
- O neurônio vitorioso tem os seus pesos ajustados e dessa forma ele reagirá mais forte para uma entrada na próxima vez que ela for apresentada

Cooperação / Adaptação Sináptica

- Nesse caso, a atualização dos pesos de um neurônio é dada por:

$$W_v(n+1) = W_v(n) + \theta(v, s)\eta(n)[D(t) - W_v(n)]$$

- $W_v(n+1)$ representa o vetor de pesos atualizado de um neurônio v
- $W_v(n)$ representa o vetor de pesos atual de um neurônio v
- $\theta(v, s)$ representa a função de vizinhança (entre um neurônio v e o neurônio vencedor s)
- $\eta(n)$ é a taxa de aprendizado (pode ser fixa ou decrementar conforme o número de iterações)
- $[D(t) - W_v(n)]$ diferença entre o exemplo e o vetor de um neurônio v na n -ésima iteração

Cooperação / Adaptação Sináptica

- **Funções de vizinhança**

- Mostram a proximidade de um neurônio da camada de saída com o BMU
- Geralmente essas funções apresentam o valor 1 caso o neurônio comparado seja o próprio BMU e descrevem até 0 conforme esses valores sejam menos próximos ao BMU

Cooperação / Adaptação Sináptica

- Funções de vizinhança

- Inversamente proporcional à distância entre o neurônio vizinho e o neurônio vencedor

$$\theta(v, s) = \frac{1}{(1 + d(v, s))^2}$$

- Função Gaussiana

$$\theta(v, s) = \exp\left(-\frac{\|d(v, s)\|^2}{2\sigma(t)^2}\right)$$

- $d(v, s)$: distância entre um neurônio v e um neurônio s na camada de saída (nº de conexões)
- Distâncias: Euclidiana (L^2) ou Suprema (L^∞)

Exercício

Considere a base de treinamento e os pesos dos neurônios apresentados abaixo. Considere uma taxa de aprendizado $\eta = 0.5$ e função de vizinhança igual ao inverso da distância Euclidiana. Faça duas iterações da rede SOM e apresente os pesos finais dos neurônios.

Exemplos de Treinamento

x_1	x_2
1	1
2	2
4	4
5	5

Neurônios

w_1	w_2
1	4
5	2

Considerações para o Aprendizado da Rede SOM

- Para bom funcionamento e convergência na prática, a taxa de aprendizado e a abertura da função gaussiana devem diminuir ao longo das iterações
 - $\eta(t) = \alpha_0 * \exp(-t/\tau_\alpha)$
 - $\sigma(t) = \sigma_0 * \exp(-t/\tau_\sigma)$
- O uso $\alpha(t)$ e $\sigma(t)$ causam respectivamente:
 - Atualização com menor “força” do neurônio vencedor que apos algumas ou várias iterações os neurônios já se parecem mais com os exemplos de treinamento
 - Cada vez mais apenas uma região mais próxima do neurônio vencedor é atualizada

Material Complementar

- Introdução aos Self Organizing Maps

<http://www.decom.ufop.br/imobilis/self-organizing-maps/>

- Mapas auto-organizáveis (redes de Kohonen)

https://www.youtube.com/watch?v=_5K3MgBQi2w

- Mapas de Kohonen

https://pt.wikipedia.org/wiki/Mapas_de_Kohonen

- Self Organizing Maps

<https://towardsdatascience.com/self-organizing-maps-ff5853a118d4>

Imagem do Dia

AS ETAPAS DE UM PROFESSOR CORRIGINDO PROVAS



Inteligência Artificial
<http://lives.ufms.br/moodle/>

Rafael Geraldeli Rossi
rafael.g.rossi@ufms.br

Slides baseados no material do Prof. Ricardo Marcacini

Referências Bibliográficas I



Kohonen, T. (1990).

The self-organizing map.

Proceedings of the IEEE, 78(9):1464–1480.